

**Національний технічний університет України
«Київський політехнічний інститут імені Ігоря Сікорського»**

Фізико-технічний інститут
Кафедра інформаційної безпеки

ПРАКТИЧНЕ ЗАНЯТТЯ №1

з дисципліни «Інтелектуальний аналіз даних»
на тему: «Базові алгоритми класифікації у Scikit-learn»

Виконав:

ХХ-ХХ

Прізвище І. Б.

Перевірила:

ступінь

Прізвище І. Б.

ЗМІСТ

1. ВСТУП	3
1.1. Мета	3
1.2. Завдання	3
2. ТЕОРЕТИЧНІ ВІДОМОСТІ	5
2.1. Задача класифікації	5
2.2. Попередня обробка даних	5
2.3. Оцінювання моделей	6
3. ВИКОНАННЯ РОБОТИ	7
3.1. Аналіз даних	7
3.2. Exploratory Data Analysis	8
3.2.1. Кореляція ознак	9
3.2.2. Розподіл значень ознак	10
3.2.3. Порівняння ознак між класами	11
3.3. Підготовка даних до навчання	13
3.4. Підбір гіперпараметрів	14
3.4.1. k-Nearest Neighbors	14
3.4.2. Support Vector Machine	14
3.5. Оцінювання моделей	15
3.6. Порівняння результатів	18
ДЖЕРЕЛА	20

1. ВСТУП

1.1. Мета

Ознайомитися з базовим workflow задачі класифікації: від вибору та аналізу даних до навчання, налаштування, порівняння та оцінювання моделей машинного навчання з використанням бібліотеки Scikit-learn.

1.2. Завдання

Для виконання лабораторної роботи необхідно:

- обрати набір даних для задачі класифікації;
- виконати первинний аналіз даних: визначити розмір набору, назви та типи ознак, цільову змінну і розподіл об'єктів за класами;
- перевірити наявність пропущених значень та виконати необхідну попередню обробку даних;
- закодувати категоріальні ознаки;
- провести базовий Exploratory Data Analysis (EDA), зокрема побудувати кореляційну матрицю числових ознак, гістограми розподілу та boxplot-и відносно цільового класу;
- розділити дані на навчальну та тестову вибірки;
- виконати масштабування ознак для алгоритмів, чутливих до їхнього масштабу;
- навчити класифікатори k-Nearest Neighbors, Decision Tree, Support Vector Machine, Random Forest та AdaBoost;
- підібрати значення `n_neighbors` для kNN;

- за допомогою `GridSearchCV` підібрати параметри `C` та `gamma` для SVM;
- оцінити якість моделей за допомогою `classification_report` та матриць помилок;
- порівняти результати всіх моделей та визначити алгоритм, який найкраще підходить для використаного набору даних.

2. ТЕОРЕТИЧНІ ВІДОМОСТІ

2.1. Задача класифікації

Класифікація — задача машинного навчання, у якій модель за набором вхідних ознак X визначає належність об'єкта до одного з наперед заданих класів.

У цій роботі використовується набір даних UNSW-NB15, що містить характеристики мережевого трафіку та мітки нормальної і шкідливої активності [1]. На його основі розв'язується задача бінарної класифікації мережевого трафіку:

$$y = \begin{cases} 0 & \text{— нормальний трафік} \\ 1 & \text{— атака} \end{cases} \quad (2.1)$$

Модель навчається на навчальній вибірці, що містить як вхідні ознаки, так і правильні значення цільової змінної. Після навчання якість моделі оцінюється на тестовій вибірці, яка не використовується для налаштування параметрів моделі.

2.2. Попередня обробка даних

Перед навчанням моделі дані необхідно привести до форми, придатної для алгоритмів машинного навчання.

Категоріальні ознаки повинні бути перетворені у числове представлення. Для цього може використовуватися One-Hot Encoding, за якого кожне можливе значення категорії представляється окремою бінарною ознакою.

Для алгоритмів, чутливих до масштабу ознак, зокрема kNN та SVM, доцільно виконувати стандартизацію числових ознак:

$$x' = \frac{x - \mu}{\sigma}, \quad (2.2)$$

де μ — середнє значення ознаки, а σ — її стандартне відхилення.

Для алгоритмів на основі дерев рішень масштабування числових ознак зазвичай не є необхідним.

2.3. Оцінювання моделей

Якість моделей класифікації оцінюється за результатами порівняння прогнозованих та фактичних класів.

Основними метриками є:

1. Accuracy — частка правильно класифікованих об'єктів;
2. Precision — частка правильних позитивних прогнозів серед усіх прогнозів позитивного класу;
3. Recall — частка знайдених позитивних об'єктів серед усіх реальних об'єктів позитивного класу;
4. F1-score — гармонічне середнє між Precision та Recall.

Матриця помилок дозволяє окремо оцінити кількість правильно класифікованих об'єктів та помилок типів False Positive і False Negative.

Для підбору гіперпараметрів може використовуватися `GridSearchCV`, який перебирає задані комбінації параметрів та оцінює їх за допомогою крос-валідації.

3. ВИКОНАННЯ РОБОТИ

3.1. Аналіз даних

У наборі міститься 56 000 записів нормального трафіку та 119 341 запис атаки, тобто 31,94% і 68,06% відповідно. Клас Attack представлений приблизно вдвічі частіше за Normal.




Рисунок 3.1 – Розподіл записів UNSW-NB15 між класами Normal та Attack

Пропущені значення у використаній частині набору даних відсутні. Цільовою змінною є `label`, а `attack_cat` було виключено з вхідних ознак, оскільки ця колонка вже містить інформацію про тип атаки.

Категоріальними ознаками є `proto`, `service` та `state`. Перед навчанням моделей вони кодуються за допомогою One-Hot Encoding. Для kNN та SVM числові ознаки додатково стандартизуються, оскільки ці алгоритми чутливі до різниці масштабів значень.

3.2. Exploratory Data Analysis

UNSW-NB15 містить велику кількість числових ознак, тому будувати окремі графіки для кожної з них недоцільно. Для візуального аналізу було обрано 10 числових ознак із найбільшим абсолютним значенням кореляції з `label`.

Абсолютне значення використовується лише для вибору ознак: воно показує силу зв'язку незалежно від його напрямку. Наприклад, `dload` має кореляцію приблизно $-0,39$ з `label`, але за модулем це найбільше значення серед вибраних числових ознак.

До вибраних характеристик увійшли:

- `dload` — швидкість передавання даних від сторони призначення;
- `ct_dst_sport_ltm` — кількість недавніх з'єднань з однаковою адресою призначення та портом джерела;
- `dmean` — середній розмір пакетів від сторони призначення;
- `rate` — інтенсивність передавання пакетів;
- `swin` та `dwin` — значення TCP window для сторін джерела та призначення;
- `ct_src_dport_ltm` — кількість недавніх з'єднань з однаковою адресою джерела та портом призначення;
- `stcpb` та `dtcpb` — TCP sequence number для обох сторін;
- `is_sm_ips_ports` — ознака збігу IP-адрес і портів джерела та призначення.

3.2.1. Кореляція ознак

Для вибраних характеристик було побудовано кореляційну матрицю.




Рисунок 3.2 – Кореляційна матриця вибраних числових ознак датасету

Найбільший за модулем зв'язок із `label` має `dload` ($r \approx -0,39$). Від'ємне значення означає, що більші значення цієї характеристики частіше зустрічаються у класі Normal.

Позитивну кореляцію з класом Attack мають `ct_dst_sport_ltm` ($r \approx 0,36$), `rate` ($r \approx 0,34$) та `ct_src_dport_ltm` ($r \approx 0,31$).

Матриця також показує сильний зв'язок між окремими ознаками. Наприклад, кореляція між `swin` і `dwin` становить приблизно 0,99, а між `ct_dst_sport_ltm` та `ct_src_dport_ltm` — близько 0,91.

3.2.2. Розподіл значень ознак

Для шести ознак із найбільшою абсолютною кореляцією було побудовано гістограми.




Рисунок 3.3 – Розподіл значень вибраних числових ознак

Для `dload`, `dmean` та `rate` видно нерівномірні розподіли: більшість спостережень концентрується у нижній частині діапазону, але присутні й значно більші значення.

`ct_dst_sport_ltm` також має концентрацію на невеликих значеннях, але окрема частина записів знаходиться приблизно в діапазоні 15–20.

Ознаки `swin` та `dwin` у цьому наборі переважно приймають значення біля 0 або 255, тому їхній розподіл суттєво відрізняється від інших числових характеристик.

3.2.3. Порівняння ознак між класами

Для детальнішого порівняння значень між класами Normal та Attack було побудовано boxplot-и п'яти перших ознак.




Рисунок 3.4 – Розподіл `dload` для класів Normal та Attack




Рисунок 3.5 – Розподіл `ct_dst_sport_ltm` для класів Normal та Attack




Рисунок 3.6 – Розподіл **dmean** для класів Normal та Attack




Рисунок 3.7 – Розподіл **rate** для класів Normal та Attack




Рисунок 3.8 – Розподіл **swin** для класів Normal та Attack

На рисунку 3.4 видно значну різницю для **dload**: нормальний трафік має значно більші типові значення, тоді як для атак значення

здебільшого концентруються біля нуля. Це відповідає від'ємній кореляції цієї ознаки з `label`.

Для `ct_dst_sport_ltm`, навпаки, більші значення характерні саме для атак. У класі Normal значення переважно знаходяться біля 1, тоді як для Attack спостерігається значно більший діапазон.

`dmean` переважно має більші значення для нормального трафіку. Для `rate` спостерігається протилежна картина — атаки мають значно вищу типову інтенсивність передавання пакетів.

Для `swin` основними значеннями є 0 та 255, але їх співвідношення між двома класами суттєво відрізняється.

3.3. Підготовка даних до навчання

Повний набір містить 175 341 запис. Для навчання та порівняння моделей було використано стратифіковану підвибірку з 50 000 записів.

Зменшення вибірки дозволяє скоротити час роботи kNN, SVM та `GridSearchCV` на локальному комп'ютері. Стратифікація при цьому зберігає початкове співвідношення класів.

Після цього дані було розділено у співвідношенні 80/20:

- training set — 40 000 записів;
- test set — 10 000 записів.

Однакова test-вибірка використовувалася для оцінювання всіх моделей.

3.4. Підбір гіперпараметрів

3.4.1. k-Nearest Neighbors

Для kNN було перевірено значення `n_neighbors`: 3, 5, 7, 9, 11 та 15.

Кожне значення оцінювалося за середнім F1-score під час крос-валідації.




Рисунок 3.9 – Залежність F1-score kNN від значення `n_neighbors`

У межах перевірених значень F1-score поступово зростає. Найкращий результат отримано при `n_neighbors = 15`, тому це значення було використано у фінальній моделі.

3.4.2. Support Vector Machine

Для SVM за допомогою `GridSearchCV` було виконано пошук параметрів `C` та `gamma`.

Найкращою серед перевірених комбінацій виявилася:

- `C = 10`;
- `gamma = scale`.

Середній F1-score під час крос-валідації становив 0,9534.

3.5. Оцінювання моделей

Для кожної моделі було побудовано `classification_report` та матрицю помилок. У матрицях рядки відповідають фактичному класу, а стовпці — прогнозованому.




Рисунок 3.10 – Матриця помилок моделі kNN




Рисунок 3.11 – Матриця помилок моделі Decision Tree




Рисунок 3.12 – Матриця помилок моделі Support Vector Machine




Рисунок 3.13 – Матриця помилок моделі Random Forest




Рисунок 3.14 – Матриця помилок моделі AdaBoost

За кількістю пропущених атак найкращий результат показав SVM. Лише 34 записи класу Attack було помилково віднесено до Normal. Водночас модель створила 617 хибних спрацювань для нормального трафіку.

Random Forest пропустив 172 атаки та помилково визначив 377 нормальних з'єднань як атаки. Його помилки розподілені більш рівномірно між двома класами.

kNN пропустив 251 атаку, Decision Tree — 321, а AdaBoost — 128. Водночас AdaBoost має найбільшу кількість False Positive: 813 нормальних записів було визначено як Attack.

3.6. Порівняння результатів




Рисунок 3.15 – Порівняння Accuracy, Precision, Recall та F1-score п'яти моделей

Найбільший F1-score отримав Random Forest — 0,9603. Його Accuracy становить 0,9451, Precision — 0,9462, а Recall — 0,9747.

SVM отримав дещо нижчий F1-score — 0,9546, однак має найбільший Recall — 0,9950. Тобто ця модель пропускає найменше атак, але частіше помилково відносить нормальний трафік до атак.

kNN та Decision Tree показали близькі результати: F1-score становить 0,9527 та 0,9520 відповідно.

Найнижчий загальний результат отримав AdaBoost: Accuracy — 0,9059, F1-score — 0,9342.

За сукупністю використаних метрик найкращою моделлю для цього експерименту є Random Forest.

ДЖЕРЕЛА

- [1] dhoogla, «UNSW-NB15». Дата звернення: 2026. 29 верес. [URL]. Доступний у: <https://www.kaggle.com/datasets/dhoogla/unswnb15>